

****[오프닝 및 과제 소개]****

****[Slide 1: 먼저, 보여드리겠습니다]****

(발표자, 영상을 재생하며 시선을 집중시킴)

"안녕하십니까, 팀 '오족보행'입니다. 본격적인 발표에 앞서 영상 하나를 먼저 보여드리겠습니다."

****[Slide 2: 타이틀 슬라이드]****

(자신감 있는 목소리로 전환)

"저희의 딥러닝 팀 프로젝트 최종 과제는 바로 ****VLN(Vision-and-Language Navigation) Next-Action Prediction****입니다."

사전 학습된 거대 멀티모달 모델인 'Qwen3-VL-2B'를 활용하여, 로봇의 1인칭 카메라 영상과 텍스트 지시문만을 조합해 다음 행동을 예측해 냅니다. 이 거대한 모델을 저희 환경에 맞게 적용하기 위해, 파라미터 효율적 미세조정 방식인 ****LoRA(Low-Rank Adaptation)**** 기법을 핵심으로 사용했습니다."

****[Slide 3: 5주의 여정]****

"이 시연 영상을 만들기까지 저희는 5주의 빌드업 과정을 거쳤습니다."

* 1주차에는 Isaac Lab 시뮬레이터 환경을 구축하고, 로봇을 수동으로 제어하며 물리 엔진에 적응하는 시간을 가졌습니다. 초기 설정 중 버전 호환성 문제가 발생했으나, Isaac Lab 2.3.0 버전으로 맞추어 문제를 해결했습니다.

* 2주차에는 정규식을 활용해 텍스트 데이터를 제어 속도로 변환하는 '규칙 기반 제어' 방식을 실험했습니다. 해당 과정은 교내 PC를 이용해 원격 서버 접속 환경을 구축한 뒤 진행했습니다.

* 3주차에는 사전 학습된 SigLIP2 텍스트 인코더의 가중치를 동결(Freeze)하고, 여기에 가벼운 다층 퍼셉트론(MLP)을 결합하여 자연어 명령을 로봇의 제어 속도로 변환하는 모델 학습을 진행했습니다.

* 그리고 4, 5주차인 현재, 로봇이 시야와 명령을 종합해 스스로 행동을 결정(텍스트 출력)하는 멀티모달(Qwen3-VL) End-to-End 환경을 구축했습니다. 작은 학습 모델에서 거대한 페루프 시스템으로 로봇의 지능을 단계별로 확장해 나간 뜻깊은 경험이었습니

(멀티모달: 다른 성격의 두 데이터를 하나로 융합해 결론을 내는 것)

****[Slide 4: 우리의 방법 - AI 에이전트와 5단계]****

"초기 저희 팀은 VLN 도메인에 대한 지식이 깊지 않았습니다. 이를 극복하기 위해 ****Claude Code**와 같은 AI 코딩 에이전트**를 단순 보조자가 아닌, 구조를 토론하고 검증하는 '동료 엔지니어'로 삼았습니다."

저희는 VLN이 뭔지도 모르는 상태에서 AI 코딩 에이전트를 동료 삼아 과제를 해결했습니다.

첫째, 처음에는 개념 이해와 탐색에 집중했습니다. VLN이 무엇인지, 인코더·디코더가 무엇인지 AI에게 기초부터 물어보며 학습했습니다.

둘째, 플랜 모드로 AI가 세운 계획이 내가 원하는 방향과 과제 요구사항에 맞는지 대화하며 구체적으로 방향을 다듬었습니다.

셋째, 본학습 전에 어떤 학습이 효과적인지 작은 데이터로 먼저 돌려보고, 최적의 방향을 알아서 찾고 검증하도록 루프를 만들어 자동화했습니다.

마지막으로, 검증된 방법이 결정된 후 그 설정 그대로 최종 풀 학습을 진행했습니다. 특히 playmcp를 활용해 풀학습 상황을 1시간마다 카카오톡으로 실시간 알림을 받으며 안전하게 모니터링했습니다.

****[Slide 5: 모델 구조 - 이미지가 어떻게 행동이 되나]****

(화면의 모델 흐름도를 손으로 짚으며)

"모델의 내부를 들여다보겠습니다. 로봇이 바라보는 연속된 2장의 이미지([B, 2, 3, 256, 256])는 비전 인코더인 ViT를 거쳐 '시각 토큰'으로 변환됩니다. 즉, **이미지를 쪼개어 단어처럼 만드는 것**입니다.

이 시각 단어들은 텍스트 지시문과 나란히 이어 붙여집니다. Qwen3 디코더는 이 글과 그림이 섞인 문맥을 읽고, 직전 프레임과 현재 프레임의 차이에서 발생하는 '움직임'까지 계산하여, 최종적으로 4가지 행동 중 하나를 텍스트 형태로 추론해 냅니다."

****[Slide 6: 실제 학습 데이터 - 한 장 들여다보기]****

"다음은 저희가 모델 학습에 사용한 실제 데이터 샘플입니다.

보시는 것처럼 로봇에게 주어지는 입력값은 크게 두 가지입니다. 먼저 로봇의 동적인 움직임 을 파악하기 위한 '직전 화면과 현재 화면' 두 장의 이미지, 그리고 최종 목적지를 알려주는 '자연어 지시문'입니다.

모델은 이 시각 정보와 언어 정보를 동시에 종합하여, 지금 당장 수행해야 할 가장 알맞은 행동을 'Turn right 15 degree'와 같은 구체적인 텍스트로 생성해 내도록 학습됩니다.

저희는 이러한 형태의 데이터 세트 총 19만 5천 장을 활용했습니다. 이처럼 방대하고 다양한 환경 데이터를 학습시킴으로써, 로봇이 처음 보는 낯선 공간에서도 사람의 지시를 완벽히 이해하고 주행할 수 있도록 모델의 일반화 성능을 높였습니다."

****[Slide 7: 아이디어 ① - 데이터를 어떻게 봤나]****

보시다시피 전진이 67%, 정지가 2%라는 수치가 나왔습니다. 사실 이 불균형을 직접 눈으로 확인한 순간이 저희 프로젝트의 진짜 출발점이었습니다.

데이터셋을 직접 분석해 보면서 '전진 편향을 어떻게 다룰 것인가?'라는 고민에 빠졌고, 바로 여기서 저희 모델의 아이디어를 얻었습니다. 뒤에서 설명 드리겠습니다.

****[Slide 8: 아이디어 ② - 설정엔 전부 근거가 있습니다]****

" LoRA 하이퍼파라미터로 학습을 진행했습니다."

****[Slide 9: 시행착오 - 첫 시도(1에폭)는 이랬습니다]****

"보시는 화면은 단 1에폭만 학습한 초기 모델의 주행 영상입니다.

보시면 **회전을 제때 못 하고 직진만 하다가 벽에 박습니다.** 앞에서 본 전진 편향이 그대로 나온 거고요.

이 실패가 이후 모든 개선의 출발점이 됐습니다."

****[Slide 10: 실험 ① - 균형 강도(0.7)의 근거]****

가장 먼저 balance_power 파라미터를 조정했습니다. 해당 값이 0.0일 때는 직진성이 강해 벽에 충돌하고, 1.0일 때는 제자리에서 회전만 하는 현상이 발생했습니다. 반복적인 테스트를 거쳐, 주행 안정성과 선회력이 가장 이상적인 균형을 이루는 최적값 0.7을 도출해 적용했습니다.

****[Slide 11: 실험 ② - 모델2 본학습 손실 곡선]****

"0.7 비율을 적용한 본학습 손실 곡선입니다.

학습이 진행되며 검증 Loss가 안정적으로 하락하고, 균형 정확도(Macro) 점수는 0.742, 그리고 초기에 가장 취약했던 **'정지 정확도'는 무려 0.875(87.5%)**까지 대폭 개선되었습니다."

****[Slide 12: 실험 ③ - 실제 주행에서 드러난 정지 문제]****

"그럼에도 실주행(Closed-loop)에서는 오프라인 평가에선 보이지 않던 맹점이 드러났습니다.

초기 모델은 목적지 근처까지 완벽히 찾아갔음에도(OSR=1), 멈추라는 '정지' 판단을 스스로 내리지 못해 방 안을 무한히 맴도는(SR=0) 현상이 나타났습니다. **정지 타이밍을 잡는 것이 실주행의 핵심 허들**이었고, 앞서 정지 데이터의 가중치를 대폭 끌어올린 것은 바로 이 현상을 타개하기 위함이었습니다."

****[Slide 13: 실험 ④ - 학습 횟수(6번)의 근거]****

"에폭(Epoch) 실험 결과입니다.

9번까지 길게 학습시켜 보았으나, 4번째 에폭에서 검증 Loss가 0.0736으로 최저점을 찍은 뒤 9에폭에서는 0.104로 튀어 오르는 과적합(Overfitting)을 확인했습니다. 무조건 오래 돌리는 것이 능사가 아님을 데이터를 통해 파악하고 6에폭에서 조기 종료했습니다."

****[Slide 14: 실험 ⑤ - 모델1 ablation]****

(발표의 학술적 하이라이트이므로 힘을 주어 강조)

"본 과제의 필수 요구사항이었던 Ablation Study 결과입니다. 저희는 로봇의 주행 실패 원인을 명확히 분리해 냈습니다.

첫째, 과거 프레임을 늘려 **'정보량'을 늘려주었더니 약점이었던 **'정지(Stop)' 정확도가 5.3% 개선**되었습니다.

둘째, LoRA 랭크를 높여 **'모델 용량'을 키워더니 혼동이 줄며 **'회전(Turn)' 능력이 대폭 향상**되었습니다.

결론적으로 **정지 실패는 과거 맥락(정보)의 부족**이었고, **전진과 회전의 혼동은 모델 표

현력(용량)의 부족**이었음을 학술적으로 규명했습니다."

****[Slide 15: 실험 ⑥ - 두 전략 병행 학습]****

"한 번의 학습에 수일이 걸리는 팀 프로젝트 특성상 리스크를 분산해야 했습니다.

저희 팀은 방금 도출한 결론을 바탕으로, 과거 정보량을 극대화한 ****'정확도 중심형(모델1)****과 데이터 비율을 보정한 ****'균형 중심형(모델2)****을 각각 다른 팀원이 동시에 병행 학습시키는 투트랙(Two-track) 전략으로 프로젝트를 완주했습니다."

****[Slide 16: 가점 - 무엇이 길을 결정하나]****

"가점 실험으로 입력 신호의 중요도를 분석했습니다. 텍스트 지시문만 주어졌을 때 정확도는 6.1%였으나, 이미지만 주었을 때는 36%로 상승했습니다.

로봇이 다음 경로를 결정하는 때 순간의 가장 결정적인 판단 근거는 텍스트가 아닌, ****'눈앞에 보이는 실시간 시각 이미지'****에 있음을 실증했습니다."

****[Slide 17: 한계와 향후 과제]****

"하지만 저희 모델은 냉정하게 말해 아직 ****'길치'****입니다. 글로벌 지도도, 장기 기억도 없기 때문입니다.

1. 시야 밖의 목표는 찾지 못하는 ****부분 관찰****의 한계
2. 지나온 길을 기억하지 못해 같은 곳을 맴도는 ****기억의 부재****
3. 자신의 오차로 인해 발생한 낯선 화면에 당황해 전진만 해버리는 ****분포 시프트(Distribution Shift)**** 현상이 가장 큰 약점으로 남아있습니다."

****[Slide 18: 마치며]****

"비록 길치 로봇이 갖는 근본적인 아키텍처의 한계를 확인했지만, 복잡한 전통 제어 시스템 없이 거대 시각-언어 모델(VLM) 단 하나만으로 페루프 자율 주행의 가능성을 직접 증명해 낸 가슴 뛰는 한 학기였습니다.

시험 기간에도 밤을 새우며 시뮬레이터와 씨름한 팀원들에게 깊은 감사를 전합니다. 이상으로 팀 오죽보행의 최종 발표를 마치겠습니다. 들어주셔서 감사합니다!"